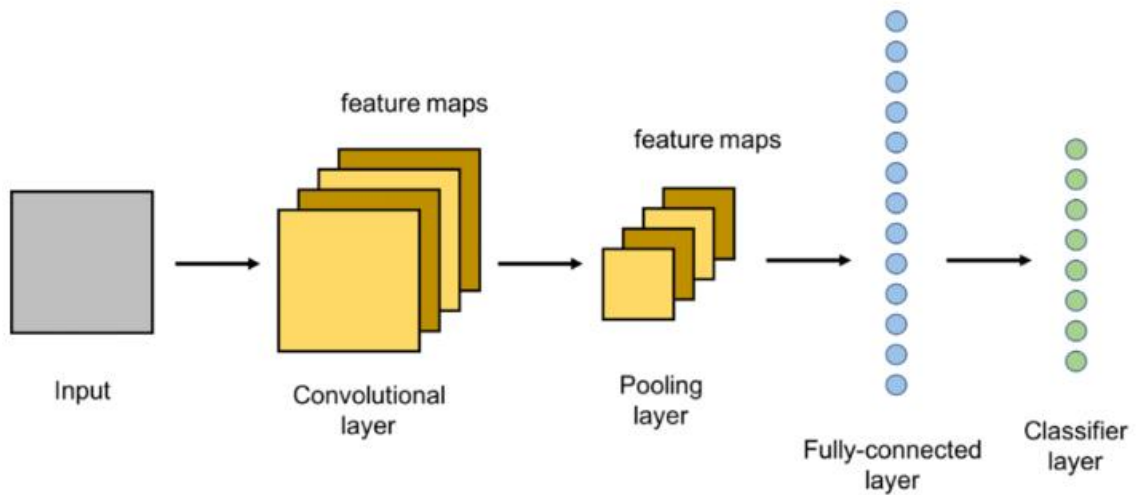


## Unidad 5. Redes neuronales convolucionales



“Programación de Inteligencia Artificial”  
Curso de Especialización en Inteligencia Artificial  
y Big Data

## Contenido

1. Introducción a las Redes Neuronales Convolucionales .....	3
1.1. ¿Qué son las CNN? Diferencias entre redes neuronales densas y convolucionales. ....	3
1.2. Aplicaciones prácticas de las CNN en la actualidad .....	4
2. Conceptos básicos de las CNN.....	5
2.1. Operación de convolución: definición y ejemplo visual. ....	5
2.2. Operación de pooling: max pooling vs average pooling.....	6
2.3. Mapas de características (feature maps) y evolución en las capas. ....	6
3. Arquitectura de una CNN .....	7
3.1. Capas típicas en una CNN: Capas convolucionales. Capas de pooling. ....	7
3.2. Profundidad, stride y padding: impacto en el diseño y el rendimiento. ....	8
3.3. Arquitecturas populares.....	9
4. Implementación de CNN con Keras/TensorFlow .....	12
4.1. Preparación del entorno de trabajo .....	12
4.1. Carga y procesamiento de las imágenes de entrada.....	12
4.2. Construcción y compilación de una CNN básica con Keras .....	14
4.3. Entrenamiento, evaluación y visualización de resultados.....	15
4.4. Uso del modelo en predicciones .....	16
5. Mejora del rendimiento, técnicas avanzadas y optimización.....	17
5.1. Tratamiento del overfitting mediante regularización.....	17
5.2. Data augmentation: rotación, escalado, traslación, etc. ....	17
5.3. Ajuste de la tasa de aprendizaje.....	17

# 1. Introducción a las Redes Neuronales Convolucionales

Las redes neuronales convolucionales (CNN, por sus siglas en inglés: Convolutional Neural Networks) son un tipo especializado de red neuronal artificial diseñada para procesar datos con una estructura similar a una cuadrícula, como las imágenes. Se han convertido en la piedra angular de la visión por computador y han revolucionado aplicaciones en campos como la clasificación de imágenes, la detección de objetos y la segmentación semántica.

Las CNN se inspiran en la organización del sistema visual de los mamíferos, particularmente en el trabajo pionero de Hubel y Wiesel en la corteza visual primaria. Estas redes explotan la estructura espacial de los datos de entrada mediante operaciones de convolución, que permiten extraer características jerárquicas con un menor número de parámetros en comparación con las redes densamente conectadas.

## 1.1. ¿Qué son las CNN? Diferencias entre redes neuronales densas y convolucionales.

Las redes neuronales tradicionales, también llamadas redes densas o fully connected (FC), conectan cada neurona de una capa con todas las neuronas de la siguiente. Aunque esto les permite modelar relaciones complejas, tiene un gran inconveniente cuando se aplican a imágenes: la cantidad de parámetros crece exponencialmente con el tamaño de la imagen, lo que hace que el entrenamiento sea ineficiente y propenso al sobreajuste.

Las CNN abordan este problema utilizando tres ideas clave:

- **Convolución y filtros:** En lugar de conectar todas las neuronas con todas las entradas, las CNN aplican filtros ("kernels") que recorren la imagen extrayendo características locales.
- **Compartición de pesos:** Un mismo filtro se usa en toda la imagen, reduciendo drásticamente la cantidad de parámetros y mejorando la generalización.
- **Submuestreo (pooling):** reduce la dimensionalidad de las características extraídas, haciéndolas más robustas a pequeñas variaciones y reduciendo el costo computacional.

Mientras que una red densa aprendería características sin considerar la relación espacial entre los píxeles, una CNN capta patrones como bordes, texturas y formas de manera jerárquica. Por ejemplo, en una red convolucional entrenada para el reconocimiento facial, las primeras capas pueden detectar bordes, las intermedias estructuras como ojos y nariz, y las finales patrones específicos que identifican a una persona.


## 1.2. Aplicaciones prácticas de las CNN en la actualidad

Las CNN han impulsado avances en diversas aplicaciones del mundo real, destacándose en problemas donde el reconocimiento de patrones visuales es clave:


- **Clasificación de imágenes:** Modelos como AlexNet, VGG y ResNet han demostrado un rendimiento excepcional en conjuntos de datos como ImageNet, permitiendo etiquetar imágenes con alta precisión.
- **Detección de objetos:** Algoritmos como YOLO (You Only Look Once) y Faster R-CNN identifican y localizan múltiples objetos en una imagen en tiempo real, con aplicaciones en seguridad, automoción y análisis de vídeo.
- **Segmentación semántica:** Modelos como U-Net y DeepLab permiten dividir una imagen en regiones específicas, crucial para medicina (segmentación de órganos en imágenes médicas) y vehículos autónomos.
- **Reconocimiento facial:** CNNs son la base de los sistemas de autenticación biométrica en smartphones y aplicaciones de seguridad.
- **Generación de imágenes:** Redes generativas adversarias (GANs) basadas en CNN pueden crear imágenes sintéticas realistas, utilizadas en diseño, entretenimiento y restauración de imágenes históricas.




Image Recognition



Semantic Segmentation



Object Detection




Instance Segmentation

Las redes neuronales convolucionales continúan evolucionando y adaptándose a nuevos desafíos, consolidándose como una herramienta fundamental en inteligencia artificial y aprendizaje profundo.

## 2. Conceptos básicos de las CNN

### 2.1. Operación de convolución: definición y ejemplo visual.

La convolución es la operación fundamental en las CNN. Se basa en aplicar un filtro o kernel sobre una imagen de entrada para extraer características locales, patrones como bordes, texturas o formas. El kernel es una matriz de pesos que se desliza sobre la imagen, multiplicando sus valores por los píxeles correspondientes y sumando el resultado. De forma más simple, cuando cada píxel de la imagen de salida es una función matemática de los píxeles cercanos (incluido él mismo) de la imagen de entrada, el kernel es esa función. Esto genera una nueva representación conocida como **mapa de características (feature map)**. En la imagen vemos una operación de convolución con stride = 2.



Una operación de convolución básica que se aplica a una imagen bidimensional  $I$  como entrada, usando un kernel o filtro  $K$  bidimensional y que nos da como resultado una nueva imagen  $S$  sería, por ejemplo:

$$S(i, j) = (K * I)(i, j) = \sum_m \sum_n I(m, n) K(i - m, j - n)$$


#### Parámetros clave en la convolución

- **Tamaño del kernel:** define la dimensión del filtro (ej. 3x3, 5x5). Tamaños más pequeños capturan detalles locales, mientras que los grandes detectan estructuras más generales.
- **Stride (paso):** es el número de píxeles que se mueve el kernel en cada iteración sobre la imagen. Un stride mayor reduce el tamaño del mapa de características.
- **Padding (relleno):** determina si se agregan ceros alrededor de la imagen para mantener el tamaño de la salida. Tipos:
  - *Valid Padding:* sin ceros, reduce el tamaño del output.
  - *Same Padding:* agrega ceros para mantener el tamaño de la imagen.

## 2.2. Operación de pooling: max pooling vs average pooling.

El pooling es una técnica de reducción de dimensionalidad (subsampling) que disminuye la cantidad de información, manteniendo las características más relevantes. Se divide la imagen convolucionada en recuadros de tamaño  $N \times N$ , y de cada recuadro se toma un único valor. Existen principalmente dos técnicas:

- **Max Pooling:** Selecciona el valor máximo en una región de la imagen, preservando las características más intensas y eliminando ruido.
- **Average Pooling:** Calcula el promedio de los valores en una región, generando una representación más suave.



Operaciones de pooling de 2x2

La etapa de pooling ofrece una **doble ventaja**: reduce el volumen de datos al seleccionar un valor representativo de cada zona, reduciendo coste computacional (cuanto mayor es esta zona, mayor es la reducción, pero también la pérdida de detalle) y, a la vez, independiza al modelo de las variaciones en la imagen, haciéndolo tolerante a las distorsiones.

## 2.3. Mapas de características (feature maps) y evolución en las capas.

Cada capa convolucional genera un conjunto de **mapas de características** que capturan patrones específicos. En las primeras capas, los filtros detectan bordes y texturas simples. A medida que avanzamos en la red, se identifican estructuras más complejas como formas y objetos.

El proceso de convolución y pooling se repite en múltiples capas, permitiendo que la red aprenda representaciones jerárquicas de las imágenes. Este mecanismo es clave para el éxito de las CNN en tareas de visión por computador.


### 3. Arquitectura de una CNN

Las redes neuronales convolucionales (CNN) están compuestas por una serie de capas especializadas que trabajan en conjunto para extraer características y realizar tareas como la clasificación de imágenes. La arquitectura de una CNN está diseñada para aprovechar la estructura espacial de los datos de entrada mediante operaciones de convolución y reducción de dimensiones, organizando sus capas de forma jerarquizada.


#### 3.1. Capas típicas en una CNN: capas convolucionales y capas de pooling

Una CNN típica está formada por varias capas interconectadas que transforman la imagen de entrada en una representación más abstracta. Las capas principales incluyen:

- **Capa de entrada:** es la 1ª capa de la red y recibe la imagen o los datos que queremos procesar. Generalmente debemos proporcionar imágenes representadas como tensores con la forma (altura, anchura, canales). Por ejemplo, una imagen en escala de grises de  $28 \times 28$  píxeles se representaría como (28, 28, 1), mientras que una imagen RGB sería (28, 28, 3) (3 canales por RGB).
- **Capas convolucionales:** son la base de las CNN. Aplican filtros (kernels) sobre la imagen para extraer características como bordes, texturas y patrones. Cada neurona en esta capa está conectada a una región local de la entrada en lugar de a todas las neuronas de la capa anterior, como en una red densa.
- **Capas de pooling (subsampling o downsampling):** su objetivo es reducir la dimensionalidad de los mapas de características generados en las capas convolucionales, disminuyendo la cantidad de parámetros y mejorando la tolerancia a variaciones menores en la imagen.



- **Capas de activación:** introducen no linealidad en la red, permitiendo que ésta aprenda relaciones complejas. Algunas funciones de activación comunes son:
  - **ReLU** (Rectified Linear Unit):  $f(x) = \max(0, x)$ , que introduce sparsity y acelera el entrenamiento.
  - **Sigmoid:**  $f(x) = 1 / (1 + e^{(-x)})$ , utilizada en tareas donde se requiere una salida probabilística.
  - **Tanh:**  $f(x) = (e^x - e^{-x}) / (e^x + e^{-x})$ , similar a Sigmoid pero con valores en el rango  $[-1, 1]$ .
- **Capa de aplanamiento (flattening):** es un paso crucial que transforma los datos multidimensionales en un formato lineal. Tras las etapas de convolución y pooling, que extraen y resumen las características de la imagen, el flattening convierte las matrices resultantes en un vector unidimensional. Este proceso "aplana" cada matriz de características, colocando sus valores en fila, y luego concatena todos estos vectores en uno solo. El resultado es un vector largo que contiene todas las características relevantes extraídas de la imagen original, preparando los datos para su procesamiento en las capas completamente conectadas de la red neuronal, que forman el clasificador.



- **Capas densas (fully connected):** representan la fase de clasificación, se encuentran en la parte final de la arquitectura y están completamente conectadas. Transforman la información extraída por las capas convolucionales en una representación apta para la tarea final, como la clasificación binaria o categórica.

### 3.2. Profundidad, stride y padding: impacto en el diseño y el rendimiento.

El diseño de una CNN depende de varios parámetros que afectan su rendimiento y capacidad de aprendizaje:

- **Profundidad:** se refiere a la cantidad de capas convolucionales y de pooling en la red. Redes más profundas pueden capturar características más abstractas, pero requieren más datos y poder computacional para su entrenamiento.

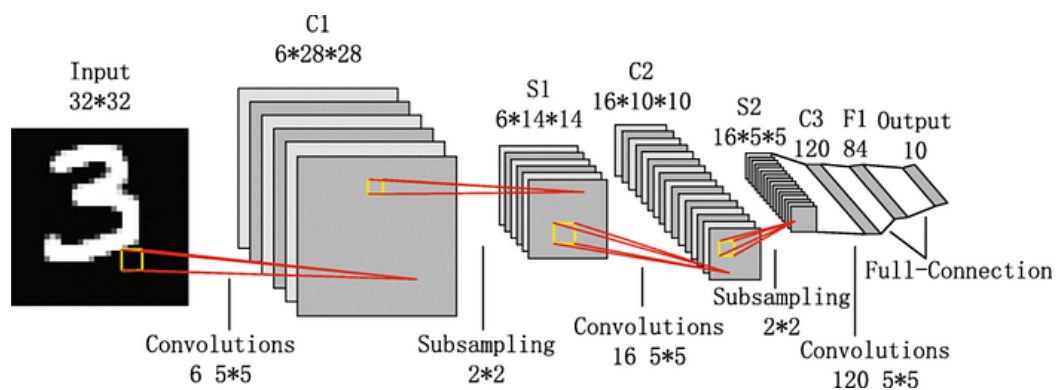


- **Stride:** un stride mayor reduce el tamaño del mapa de características, pero puede perder información importante.
- **Padding:**

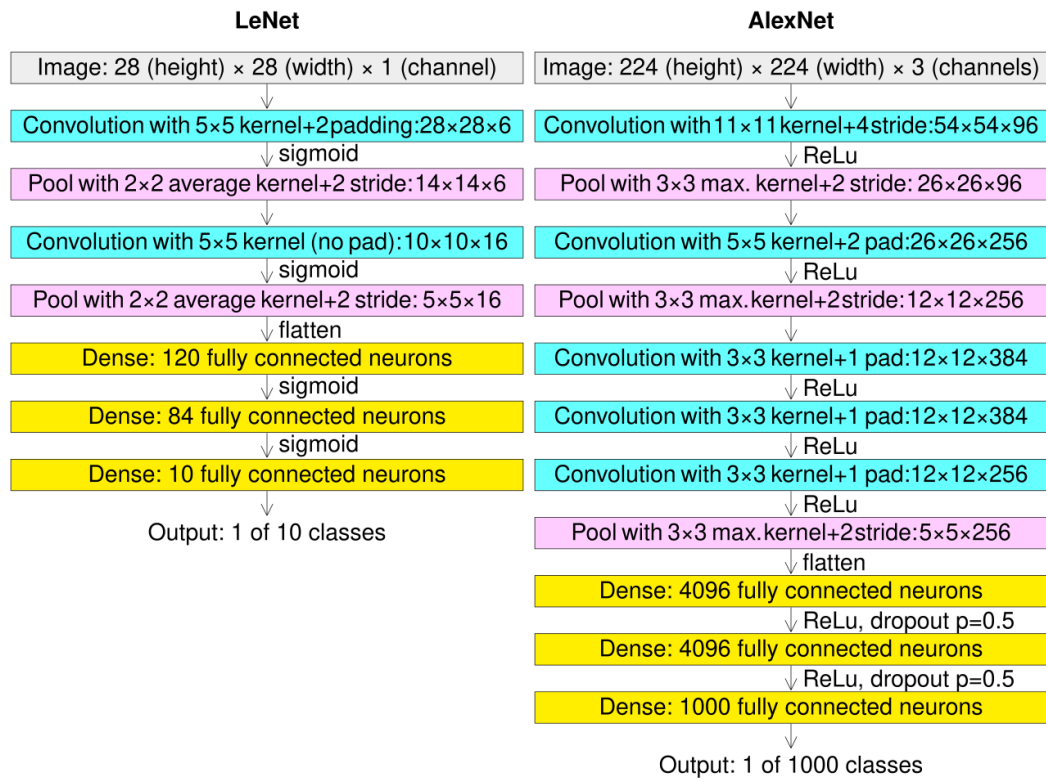
### 3.3. Arquitecturas populares

Existen varias arquitecturas populares de CNN, cada una con características específicas optimizadas para diferentes tareas:


- **LeNet-5:** una de las primeras CNN, diseñada para la clasificación de dígitos escritos a mano en el dataset MNIST. Consta de 2 capas convolucionales seguidas de capas de pooling y 3 capas densas al final.



- **AlexNet:** Introducida en 2012, fue la primera en demostrar el poder de las CNN en ImageNet. Utiliza ReLU, dropout y múltiples GPUs para mejorar el rendimiento. Veamos una comparativa de LeNet-5 y AlexNet:

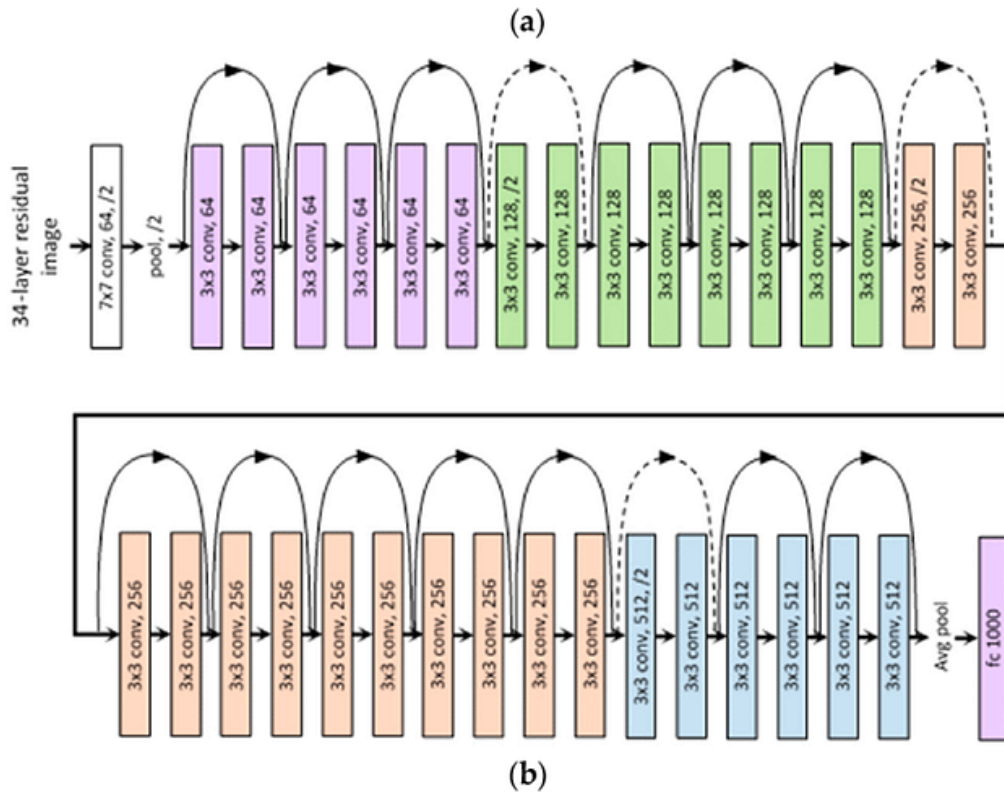


- **VGG16/VGG19**: Proponen una arquitectura profunda con muchas capas convolucionales pequeñas (3x3), seguidas de capas de pooling y densas. Son fáciles de interpretar, pero computacionalmente costosas.



- **ResNet** (Residual Networks): Introduce conexiones residuales que permiten entrenar redes extremadamente profundas (hasta 152 capas)


evitando el problema del desvanecimiento del gradiente. Veamos el ejemplo de ResNet-34:



- **Inception** (GoogLeNet): usa módulos Inception que combinan convoluciones de diferentes tamaños en una misma capa, optimizando el uso de parámetros y mejorando la eficiencia computacional.

Cada una de estas arquitecturas ha representado un avance significativo en la visión por computador y sigue siendo la base para modelos modernos utilizados en aplicaciones del mundo real.

En la siguiente imagen podemos ver la arquitectura de Inception-v3.



## 4. Implementación de CNN con Keras/TensorFlow

En este apartado se presenta una guía práctica para implementar una red neuronal convolucional (CNN) utilizando Keras. Se abordarán desde la configuración del entorno hasta el entrenamiento y evaluación del modelo sobre un conjunto de datos estándar.

### 4.1. Preparación del entorno de trabajo

Antes de comenzar con la implementación, es necesario asegurarse de que Keras y TensorFlow estén correctamente instalados. Se recomienda utilizar un entorno virtual para mantener organizadas las dependencias. También se pueden utilizar entornos como Google Colab, que ya incluyen estas bibliotecas preinstaladas.

#### 4.1. Carga y procesamiento de las imágenes de entrada

Para poder procesar las imágenes de entrada como datos de entrenamiento es ampliamente conocido y utilizado el método `image_dataset_from_directory` del paquete `keras.utils`. Este método acepta, entre otros, los siguientes parámetros:

- La carpeta de donde tomar las imágenes (en una ruta absoluta o relativa).
- **labels**: indica qué etiquetas se deben tomar para clasificar las imágenes de entrada. Un valor muy habitual es `inferred`, para que se deduzcan de las subcarpetas existentes dentro de la carpeta principal indicada en el parámetro anterior.
- **label\_mode**: indica el modo de etiquetado que se aplicará. Algunos valores habituales son `binary` (para clasificadores binarios medidos con entropía cruzada binaria), `categorical` (para clasificadores categóricos medidos con entropía cruzada categórica), o `int` (para otras clasificaciones medidas con otras métricas).
- **class\_names**: sólo en el caso de que el parámetro `labels` sea `inferred`, podemos indicar aquí en forma de lista los valores de las categorías que queremos identificar (y que deben coincidir con los nombres de las subcarpetas existentes).
- **color\_mode**: puede tomar los valores `grayscale`, `rgb` (valor por defecto) o `rgba`.
- **batch\_size**: tamaño de los paquetes de imágenes que se formarán para pasarlos al modelo. Por defecto es 32.
- **image\_size**: tupla indicando el tamaño de las imágenes de entrada (altura y anchura, en ese orden).

Aquí vemos un ejemplo donde indicamos que las imágenes de entrenamiento están en una subcarpeta train en la carpeta actual. Las queremos proporcionar con un tamaño de 224x224, y dentro de esa carpeta hay dos subcarpetas con las categorías perros y gatos (clasificación binaria). La carpeta test tiene una distribución similar para el test:

```
from keras.utils import image_dataset_from_directory

train_dataset = image_dataset_from_directory(
    './train',
    image_size=(224, 224),
    labels='inferred',
    label_mode='binary',
    class_names=['perros', 'gatos']
)

test_dataset = image_dataset_from_directory(
    './test',
    image_size=(224, 224),
    labels='inferred',
    label_mode='binary',
    class_names=['perros', 'gatos']
)
```

Además, resulta conveniente **normalizar** los valores de la imagen en una escala de 0 a 1; para ello tenemos disponible la clase Rescaling del paquete keras.layers. Por otra parte, con el objetivo de prevenir el overfitting y mejorar las métricas, suele ser importante aplicar la técnica del **data augmentation**, la cual permite generar múltiples datos a partir de uno en particular. En este caso, a partir de una imagen podemos generar otras similares aplicando algunas transformaciones: voltear, rotar, ampliar... Para esto tenemos disponibles las clases RandomFlip, RandomRotation, RandomZoom y/o RandomTranslation, entre otras. Veamos un ejemplo combinado aplicando ambas cosas al conjunto de entrenamiento, y sólo el escalado al de test:

```
from keras.layers import Rescaling, RandomFlip, RandomRotation,
RandomZoom, RandomTranslation

normalization = Rescaling(1./255)

data_augmentation = Sequential([
    RandomFlip("horizontal"),           # Volteo horizontal
    RandomRotation(0.2),                 # Rotaciones 20% de 360°
    RandomZoom(0.1),                    # Zoom hasta 10%
    RandomTranslation(0.1, 0.1)         # Desplaz. vertical y horizontal
])

train_dataset = train_dataset.map(lambda x, y:
    (data_augmentation(normalization(x)), y))
```

```
test_dataset = test_dataset.map(lambda x, y: (normalization(x), y))
```

## 4.2. Construcción y compilación de una CNN básica con Keras

Además de capas ya conocidas, como son “Input” y “Dense”, vamos a añadir capas específicas para implementar las arquitecturas convolucionales, como son:

- **Conv2D**: capa convolucional.
- **MaxPooling2D**: capa para realizar el pooling.
- **Flatten**: aplanado previo a la fase de capas Dense.

```
import tensorflow as tf
from tensorflow import keras
from tensorflow.keras.layers import Conv2D, MaxPooling2D, Flatten,
Dense

model = keras.Sequential([
    Conv2D(32, (3, 3), activation='relu', input_shape=(224, 224, 1)),
    MaxPooling2D((2, 2)),
    Conv2D(64, (3, 3), activation='relu'),
    MaxPooling2D((2, 2)),
    Flatten(),
    Dense(64, activation='relu'),
    Dense(10, activation='softmax')
])

model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])
```

Este modelo consiste en 2 capas convolucionales con ReLU como función de activación, seguidas de capas de pooling y una capa completamente conectada (la tradicional capa oculta de neuronas vista en la unidad anterior) para la clasificación. Algunos aspectos relevantes a comentar:

- En las capas Conv2D especificamos el número de filtros distintos de convolución que se aplicarán.
- En las capas MaxPooling2D definimos el tamaño de la matriz de *pooling* (2x2, en este caso).
- Tras el aplanado (Flatten), pasamos al clasificador que se trata de una red neuronal tradicional mediante las capas Dense. La primera que añadamos tomará las conexiones de la capa *Flatten*. Dependiendo del tamaño final de esa capa deberemos darle un tamaño intermedio adecuado.

El número de filtros por capa es totalmente experimental. Podemos probar hasta que encontremos resultados satisfactorios. Es habitual definir pocos filtros en las

primeras capas (donde el tamaño de las imágenes aún puede ser grande) y aumentarlo en capas posteriores, donde ya se han reducido con operaciones de *pooling*.

En la fase del clasificador, podemos añadir tantas capas intermedias como queramos, y finalizar con una capa de salida que tendrá tantas neuronas como elementos queramos clasificar:

- Si sólo queremos distinguir entre 2 estados, podemos colocar una neurona de salida con función de activación sigmoide. La función de coste, si es un problema de clasificación, podría ser la entropía cruzada binaria (`binary_crossentropy`).
- Si queremos distinguir entre más de 2 categorías, añadiremos una neurona por cada categoría, con activación softmax. En este caso, la función de coste al compilar la red será la entropía cruzada categórica (`categorical_crossentropy`). En el ejemplo la capa de salida tiene 10 neuronas porque querríamos clasificar una imagen entre 10 posibles estados (reconocer dígitos del 0 al 9, por ejemplo).

#### 4.3. Entrenamiento, evaluación y visualización de resultados.

Una vez construida la arquitectura de la CNN, el siguiente paso es entrenarla utilizando los datos previamente cargados y procesados. En este apartado, se explicará cómo llevar a cabo el entrenamiento del modelo, evaluar su rendimiento y visualizar los resultados obtenidos.

El entrenamiento de la CNN se realiza con el método `fit()`, donde se le pasan los datos de entrenamiento, el número de épocas y, opcionalmente, los datos de validación. Durante este proceso, el modelo ajustará sus pesos a través de la retropropagación y optimización, buscando minimizar la función de pérdida definida.

```
history = model.fit(  
    train_dataset,  
    validation_data=test_dataset,  
    epochs=20,  
    batch_size=32  
)
```

Tras el entrenamiento, es crucial evaluar el modelo para medir su rendimiento sobre el conjunto de prueba. Esto nos permite verificar si el modelo ha aprendido correctamente o si ha caído en sobreajuste (*overfitting*). También podemos analizar cómo ha progresado el modelo durante el entrenamiento, mostrando de forma gráfica las métricas almacenadas en `history`.

```

# Evaluación del modelo en el conjunto de test
loss, accuracy = model.evaluate(test_dataset)

print(f"Pérdida en test: {loss:.4f}")
print(f"Precisión en test: {accuracy:.4f}")

# Visualización de la evolución del entrenamiento
import matplotlib.pyplot as plt

# Extraer los valores del historial
epochs_range = range(epochs)
train_loss = history.history['loss']
val_loss = history.history['val_loss']
train_acc = history.history['accuracy']
val_acc = history.history['val_accuracy']

plt.figure(figsize=(12, 4))
plt.subplot(1, 2, 1)
plt.plot(epochs_range, train_loss, label='Pérdida de
entrenamiento')
plt.plot(epochs_range, val_loss, label='Pérdida de validación')
plt.xlabel('Épocas')
plt.ylabel('Pérdida')
plt.legend()
plt.title('Evolución de la Pérdida')

plt.subplot(1, 2, 2)
plt.plot(epochs_range, train_acc, label='Precisión de
entrenamiento')
plt.plot(epochs_range, val_acc, label='Precisión de validación')
plt.xlabel('Épocas')
plt.ylabel('Precisión')
plt.legend()
plt.title('Evolución de la Precisión')

plt.show()

```

#### 4.4. Uso del modelo en predicciones

Una vez que el modelo ha sido entrenado, se puede utilizar para realizar predicciones sobre nuevas imágenes. Para ello, es necesario cargar la imagen, procesarla de la misma manera que las imágenes de entrenamiento y pasarla al modelo.

```

import numpy as np
from tensorflow.keras.preprocessing import image

# Cargar la imagen y preprocesarla

```



```
img = image.load_img("imagen_nueva.jpg", target_size=(224, 224))
img_array = image.img_to_array(img)
img_array = np.expand_dims(img_array, axis=0) # Añadir a batch
img_array /= 255.0 # Normalización

# Realizar la predicción
prediccion = model.predict(img_array)
clase_predicha = np.argmax(prediccion)
print(f"La imagen pertenece a la clase: {clase_predicha}")
```

## 5. Mejora del rendimiento, técnicas avanzadas y optimización

La mejora del

### 5.1. Tratamiento del overfitting mediante regularización

El overfitting es muy habitual en redes convolucionales, recordemos que éste ocurre cuando el modelo se ajusta demasiado a los datos de entrenamiento y no generaliza bien a datos nuevos. Algunas técnicas para mitigar esto son:

- **Dropout:** desactiva aleatoriamente un porcentaje de neuronas en cada iteración para evitar la dependencia excesiva en ciertas conexiones.
- **Regularización L1/L2:** agrega penalizaciones a los pesos para evitar valores excesivos

Veamos la sintaxis de ambas técnicas en el siguiente código:

```
from tensorflow.keras.layers import Dropout
from tensorflow.keras.regularizers import l2

model.add(Dropout(0.5))

model.add(Dense(128, activation='relu', kernel_regularizer=l2(0.01)))
```

También podemos emplear técnicas como “data augmentation”, entre otras.

### 5.2. Data augmentation: rotación, escalado, traslación, etc.

Uso de ImageDataGenerator o keras.preprocessing.

### 5.3. Ajuste de la tasa de aprendizaje

La tasa de aprendizaje (`learning_rate`) controla el tamaño de los pasos en la actualización de los pesos. Un valor demasiado alto puede hacer que el modelo no converja, mientras que un valor demasiado bajo puede hacer que el entrenamiento sea lento.

Se pueden utilizar estrategias como:

- Tasa de aprendizaje constante: Se fija un valor y se mantiene durante todo el entrenamiento.
- Decaimiento de la tasa de aprendizaje: Se reduce progresivamente a medida que avanza el entrenamiento para evitar oscilaciones.
- Scheduler de tasa de aprendizaje: Keras proporciona el callback `ReduceLROnPlateau`, que ajusta dinámicamente la tasa cuando la métrica de validación no mejora.

```
from tensorflow.keras.callbacks import ReduceLROnPlateau

lr_scheduler = ReduceLROnPlateau(monitor='val_loss', factor=0.5,
patience=3, verbose=1)
```

## 9. Técnicas de tratamiento de imagen

El preprocesamiento de imágenes es una etapa fundamental en el desarrollo de redes neuronales convolucionales. Su objetivo es optimizar la calidad de las imágenes para mejorar el rendimiento del modelo. Existen diversas librerías, como son Pillow/PIL y OpenCV (`cv2`); en este apartado trabajaremos con OpenCV, ya que es una de las librerías más utilizadas para estas tareas debido a su eficiencia y facilidad de uso. Veremos que técnicas como la normalización, el filtrado y la detección de bordes ayudan a optimizar el rendimiento del modelo y su capacidad de generalización.

### 1. Importancia del Preprocesamiento en CNN

Las imágenes pueden venir en distintos formatos, resoluciones y condiciones de iluminación, lo que puede afectar la capacidad de generalización del modelo. Algunas razones por las cuales es importante el preprocesamiento son:

- Normalización de datos.
- Reducción del ruido.
- Corrección de iluminación y contraste.
- Asegurar un tamaño uniforme de las imágenes.
- Resaltar características importantes.

## 2. Operaciones de Preprocesamiento con OpenCV

### Carga y Visualización de Imágenes

```
import cv2
import matplotlib.pyplot as plt

# Cargar la imagen en escala de grises
imagen = cv2.imread('imagen.jpg', cv2.IMREAD_GRAYSCALE)

# Mostrar imagen con OpenCV (requiere ventana emergente)
cv2.imshow('Imagen', imagen)
cv2.waitKey(0)
cv2.destroyAllWindows()

# Mostrar con Matplotlib (evita problemas con colores)
plt.imshow(imagen, cmap='gray')
plt.axis('off')
plt.show()
```

### Redimensionamiento de Imágenes

Las CNN requieren un tamaño de imagen fijo. OpenCV permite redimensionar imágenes con `cv2.resize()`. Lo habitual es necesitarlo cuando las imágenes provienen de distintas fuentes con tamaños variables, o cuando se usa un modelo preentrenado que requiere dimensiones específicas.

```
dim = (224, 224) #Tamaño típico para modelos como VGG16 o ResNet
imagen_redimensionada = cv2.resize(imagen, dim,
interpolation=cv2.INTER_AREA)
```

### Normalización e Igualación de Histograma

Normalizar los valores de los píxeles mejora la estabilidad numérica del modelo. También podemos mejorar el contraste mediante ecualización. Debe usarse cuando hay grandes variaciones en la iluminación de las imágenes y para mejorar el contraste en imágenes con tonos similares.

```
imagen_normalizada = imagen_redimensionada / 255.0
imagen_ecualizada = cv2.equalizeHist(imagen)
```

## 2.4. Eliminación de Ruido con Filtros

Para reducir ruido en imágenes ruidosas, se pueden aplicar filtros:

```
# Filtro Gaussiano
imagen_suavizada = cv2.GaussianBlur(imagen, (5,5), 0)
# Filtro de mediana
imagen_median = cv2.medianBlur(imagen, 5)
```

## 2.5. Detección de Bordos con Canny

Los bordes resaltan características importantes para una CNN.

```
bordes = cv2.Canny(imagen, 100, 200)
plt.imshow(bordes, cmap='gray')
plt.axis('off')
plt.show()
```

## 2.6. Transformaciones Geométricas: Rotación y Traslación

```
# Rotación de 45 grados alrededor del centro
(h, w) = imagen.shape[:2]
M = cv2.getRotationMatrix2D((w//2, h//2), 45, 1.0)
imagen_rotada = cv2.warpAffine(imagen, M, (w, h))
```